

Universidad Tecnológica del valle de Toluca

Análisis Supervisado usando Regresión Lineal Simple

Johanan Baruc Pineda Mejia

IDGS-94

16 de Junio del 2026

1. Objetivo

Desarrollar un modelo de aprendizaje supervisado mediante regresión lineal simple para predecir la calificación de un estudiante en función de las horas de estudio.

2. Caso de Estudio

La coordinación académica de la universidad desea analizar si existe una relación entre el tiempo que estudia un alumno y su calificación final. Se utilizan los siguientes datos históricos:

Horas de Estudio	Calificación
1	50
2	55
3	60
4	65
5	70
6	75
7	80
8	85
9	90
10	95

3. Marco Teórico

3.1 Regresión Lineal Simple

La regresión lineal simple es un modelo estadístico que establece una relación lineal entre una variable independiente (X) y una variable dependiente (Y). La ecuación del modelo es:

$$Y = \beta_0 + \beta_1 X + e$$

Donde:

- β_0 = Intercepto (valor de Y cuando X = 0)
- β_1 = Pendiente (cambio en Y por cada unidad de X)
- e = Error aleatorio

3.2 Métricas de Evaluación

Para evaluar la calidad del modelo se utiliza el coeficiente de determinación R^2 , que mide la proporción de variabilidad en Y explicada por el modelo:

- $R^2 = 1.0$ modelo perfecto
- $R^2 \geq 0.9$ modelo excelente
- $R^2 \geq 0.7$ modelo bueno
- $R^2 < 0.5$ modelo pobre

4. Código: Regresión Lineal Simple

El siguiente código implementa la regresión lineal simple utilizando scikit-learn, siguiendo la misma estructura de los códigos de referencia del cuatrimestre:

```
# REGRESIÓN LINEAL SIMPLE
# Predicción de calificación en función de horas de estudio

import numpy as np
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score, mean_squared_error

# 1. DATOS HISTÓRICOS
horas = np.array([1, 2, 3, 4, 5, 6, 7, 8, 9, 10]).reshape(-1, 1)
calificacion = np.array([50, 55, 60, 65, 70, 75, 80, 85, 90, 95])

# 2. CREAR Y ENTRENAR EL MODELO
modelo = LinearRegression()
modelo.fit(horas, calificacion)

# 3. PREDICCIONES
predicciones = modelo.predict(horas)

# 4. MÉTRICAS
r2 = r2_score(calificacion, predicciones)
mse = mean_squared_error(calificacion, predicciones)
print(f'Coeficiente (pendiente): {modelo.coef_[0]:.4f}')
print(f'Intercepto: {modelo.intercept_:.4f}')
print(f'R²: {r2:.4f}')
print(f'MSE: {mse:.4f}')

# 5. PREDICCIÓN NUEVA
nueva_hora = np.array([[7.5]])
pred_nueva = modelo.predict(nueva_hora)
print(f'Predicción para 7.5 horas: {pred_nueva[0]:.2f}')
```

```
# 6. GRÁFICA
plt.figure(figsize=(8, 5))
plt.scatter(horas, calificacion, color='blue', label='Datos reales',
            zorder=5)
plt.plot(horas, predicciones, color='red', linewidth=2, label='Regresión
lineal')
plt.scatter(nueva_hora, pred_nueva, color='green', s=100,
            marker='*', label=f'Predicción 7.5h = {pred_nueva[0]:.1f}',
            zorder=6)
plt.title('Regresión Lineal Simple: Horas de Estudio vs Calificación')
plt.xlabel('Horas de Estudio')
plt.ylabel('Calificación')
plt.legend()
plt.grid(True, alpha=0.3)
plt.tight_layout()
plt.savefig('regresion_simple.png', dpi=150)
plt.show()
```

5. Interpretación de Resultados

Al ejecutar el modelo con los datos históricos se obtiene:

- Pendiente (β_1): 5.0 — por cada hora adicional de estudio, la calificación sube 5 puntos.
- Intercepto (β_0): 45.0 — calificación base sin horas de estudio.
- $R^2 = 1.0$ — el modelo explica el 100% de la variabilidad (datos perfectamente lineales).
- Predicción para 7.5 horas → calificación estimada: 82.5 puntos.

6. Extensión con Variables Adicionales

El valor del ejercicio aumenta al incorporar nuevas variables predictoras. Las variables sugeridas son:

- Asistencia (%)
- Participación (escala 0–10)
- Tareas entregadas
- Exámenes parciales

6.1 Código: Regresión Lineal Múltiple

```
# EXTENSIÓN: REGRESIÓN LINEAL MÚLTIPLE
# Al agregar más variables, el modelo se convierte en regresión múltiple

import numpy as np
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score

# DATOS CON VARIABLES ADICIONALES
# Columnas: horas_estudio, asistencia(%), participacion(0-10),
#          tareas_entregadas, examenes_parciales
X = np.array([
    [1, 70, 3, 2, 40],
    [2, 75, 4, 3, 45],
    [3, 80, 5, 4, 50],
    [4, 82, 5, 5, 55],
    [5, 85, 6, 6, 60],
    [6, 88, 7, 7, 65],
    [7, 90, 7, 8, 70],
    [8, 92, 8, 9, 75],
    [9, 95, 9, 9, 80],
    [10, 98, 10, 10, 90],
])
y = np.array([50, 55, 60, 65, 70, 75, 80, 85, 90, 95])

# ENTRENAR MODELO MÚLTIPLE
modelo_mult = LinearRegression()
modelo_mult.fit(X, y)
pred_mult = modelo_mult.predict(X)

r2_mult = r2_score(y, pred_mult)
print('Variables:',
      ['horas', 'asistencia', 'participacion', 'tareas', 'examenes'])
```

```

print('Coeficientes:', modelo_mult.coef_.round(4))
print(f'R² Múltiple: {r2_mult:.4f}')

# GRÁFICA COMPARATIVA (predicho vs real)
plt.figure(figsize=(8, 5))
plt.scatter(range(len(y)), y, color='blue', label='Real', zorder=5)
plt.plot(range(len(pred_mult)), pred_mult, color='red',
         linewidth=2, label='Predicción múltiple')
plt.title('Regresión Lineal Múltiple: Calificación Predicha vs Real')
plt.xlabel('Estudiante')
plt.ylabel('Calificación')
plt.legend()
plt.grid(True, alpha=0.3)
plt.tight_layout()
plt.savefig('regresion_multiple.png', dpi=150)
plt.show()

```

7. Respuesta a la Pregunta del Docente

¿Sigue siendo una regresión lineal simple o se convierte en regresión lineal múltiple?

Al agregar nuevas variables predictoras (asistencia, participación, tareas entregadas, exámenes parciales), el modelo se convierte en una Regresión Lineal Múltiple.

La diferencia fundamental es:

Característica	Regresión Simple	Regresión Múltiple
Variables independientes	1 (horas de estudio)	2 o más (horas + asistencia + ...)
Ecuación	$Y = \beta_0 + \beta_1 X_1$	$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n$
Complejidad	Baja	Mayor (una dimensión por variable)
Algoritmo en sklearn	LinearRegression() con X de 1 col.	LinearRegression() con X de N cols.

En conclusión, el tipo de regresión no depende del algoritmo (LinearRegression es el mismo en ambos casos), sino del número de variables independientes que se utilizan. Con una sola variable (horas de estudio) es simple; al agregar asistencia, participación, tareas y exámenes parciales, automáticamente se convierte en múltiple.

8. Conclusiones

- La regresión lineal simple demostró una relación perfectamente lineal entre horas de estudio y calificación ($R^2 = 1.0$), lo que confirma que el modelo es adecuado para estos datos.
- La ecuación obtenida (Calificación = $45 + 5 \times \text{Horas}$) permite predecir la nota de cualquier estudiante conociendo únicamente sus horas de estudio.
- Al incorporar variables adicionales (asistencia, participación, tareas, exámenes parciales), el modelo evoluciona a regresión lineal múltiple, lo que generalmente mejora la precisión de la predicción.
- El código desarrollado sigue la estructura modular de los ejemplos de clase, facilitando su comprensión y extensión.